2026.6.10

小模型或中等模型很多时候不是完全“想不到正确答案”，而是 **正确答案已经在 top5 里了，但最后没有选它**。

所以我们的论文主线已经从“怎么让模型生成更多正确答案”转向：

> 在证据已经充分、正确候选已经存在时，模型为什么不会做 evidence-conditioned final selection?

大白话就是：

模型不是没看见答案，而是被旁边更显眼、更像答案、和问题词面更近的东西带跑了。

1. **T7 规模差异实验**

模型	严格匹配	模型审核	Top-5 oracle 语义正确
Qwen2.5-1.5B-Instruct	38/185 = 20.5%	62/185 = 33.5%	141/185 = 76.2%
Qwen2.5-7B-Instruct	60/185 = 32.4%	94/185 = 50.8%	151/185 = 81.6%
Qwen2.5-14B-Instruct	72/185 = 38.9%	108/185 = 58.4%	152/185 = 82.2%
qwen3-max	122/185 (65.9%)	167/185 (90.3%)	contains 163/185 (88.1

1.5B top5 里其实经常有正确答案，但 final 远低于 top5。Qwen3-Max 明显更会选。

2. **T7 蒸馏路线对比**

包含 answer-only、multitask、short evidence aux、ECPD。

方法	是否交叉验证	Strict EM	Final semantic	Top-5 oracle	Parse erro
Base 1.5B	否，原模型	38/167 = 22.8%	62/167 = 37.1%	136/167 = 81.4%	3
Answer-only LoRA	是，5-fold	43/167 = 25.7%	77/167 = 46.1%	146/167 = 87.4%	2
只训练排序 Ranking CE	是，5-fold	26/167 = 15.6%	46/167 = 27.5%	107/167 = 64.1%	7
混合训练 Answer + Ranking	是，5-fold	78/167 = 46.7%	102/167 = 61.1%	145/167 = 86.8%	0
evidence-aux answer+ranking	是，5-fold	79/167 = 47.3%	103/167 = 61.7%	144/167 = 86.2%	0
ECPD full	是，5-fold	82/167 = 49.1%	104/167 = 62.3%	87.40%	2

answer-only 从 base 提升，但 selection gap 仍大；multitask、short evidence aux、ECPD 明显更能减少 selection failure。

只告诉小模型“答案是 A”，它会记答案格式；但告诉它“A 比 B/C/D 更有证据支持”，才更接近真正学会选择。

3. T7 强 reranker baseline

发现：

Selector	模型/规则	Final	Top-5	Selection gap	Ca
Logprob rerank	mean logprob	77/167 (46.1%)	146/167	69	
Self-consistency	duplicate majority	78/167 (46.7%)	146/167	68	
Answer-type filter	启发式 + logprob	87/167 (52.1%)	146/167	59	
Prompt-only support reranker	1.5B, 无 LoRA	87/167 (52.1%)	146/167	59	
RankGPT-style reranker	1.5B, 无 LoRA	91/167 (54.5%)	146/167	55	
ECPD / Support-aware selector	1.5B, 5-fold OOF LoRA	104/167 (62.3%)	146/167	42	
RankGPT-style（对照，非 1.5B 公平比）	7B, 无 LoRA	124/167 (74.2%)	146/167	22	
RankGPT-style（上界）	14B, 无 LoRA	135/167 (80.8%)	146/167	11	

Logprob rerank：对每个候选做 teacher-forcing：把「问题 + 证据 + 这个候选」喂回去，算生成该候选时每个 token 的平均 logprob

Self-consistency / Majority：5 个候选里如果有 重复或近重复 的答案，选 出现次数最多 的那组；并列时再用 mean logprob 打破平局。

Answer-type constrained rerank：先用 问题文本启发式 猜答案类型（人名 / 日期 / 地点 / 数字 / 组织等），过滤掉类型不匹配的候选，再在剩下的里选 logprob 最高的。

Prompt-only support reranker：对每个候选单独问模型：「这个问题 + 证据 + 该候选，是否被证据支持？」 选 support 分数最高的。

RankGPT-style reranker（A–E 菜单选择）：把 5 个候选标成 A/B/C/D/E，让模型 直接选一个字母。

ECPD / Support-aware selector：同样用 support score（A=SUPPORTED vs B=UNSUPPORTED）在固定 top-5 里重排，但模型是 5-fold OOF 训过的 LoRA。

同样 1.5B 下，ECPD 比 logprob rerank、majority、answer-type filter、prompt-only support reranker、RankGPT-style 1.5B 都强。

不是随便加个重排器就能达到 ECPD。ECPD 学到了一部分 evidence-conditioned selection 能力。

4. ECPD （ Evidence-Contrastive Preference Distillation（证据对比偏好蒸馏）） 组件消融

三种训练信号 = 三种「教什么」

教什么	白话
Answer generation（写答案）	教它「标准答案长什么样」
Support classification（支持判断）	教它「这个候选，证据撑不撑得住」
Pairwise preference（对比偏好）	教它「对的候选要比错的候选分更高」

练了什么	最终答对	候选里有没有对的	有对但选错（gap）
啥也不练（Base）	62	136	74
只练写答案	77	146 ↑	69（几乎没变）
只练支持判断	103	135 ↓	32 ↓↓
只练对比偏好	96	141	45
三项全练（Full）	104 最高	146	42

support classification 很强；pairwise preference 也有效；answer generation 主要保住写答案能力；full ECPD 不是简单相加，但整体最好。

最关键的不是“让模型多写几遍答案”，而是让它学会判断“这个候选是不是被证据支持”。

5. **MuSiQue full vs support-only**

Dataset	Context	Model	Final	Top5	Selection gap	Candidate miss	Parse
MuSiQue	full	1.5B	1/100	17/100	16/100	62/100	21/100
MuSiQue	full	7B	15/100	52/100	37/100	47/100	1/100
MuSiQue	full	14B	29/100	67/100	38/100	33/100	0/100
MuSiQue	support-only	1.5B fixed-parser	20/100	57/100	37/100	43/100	0/100
MuSiQue	support-only	7B	30/100	71/100	41/100	29/100	0/100
MuSiQue	support-only	14B	51/100	86/100	35/100	14/100	0/100

MuSiQue也有同样的问题，候选答案中有答案的概率非常高。干扰证据确实害人；但即使只给正确证据，模型也还是会把中间实体、相关实体当最终答案。

6. **100-case 机制精标**

从 MuSiQue + T7 里挑出 100 道 Top-5 里已经有正确答案，但模型最终选错了（selection gap）的题

主错误类型	数量	白话
wrong_answer_type	34	类型错了（年份/人名/组织等）
intermediate_entity	29	选了桥接/中间实体（多跳路上的“跳板”）
mentioned_only	17	选了证据里提过、但不是最终答案的实体
unsupported_or_artifact	13	unsupported 或格式/解析 artifact
comparison_direction	7	比较题方向反了

主要类型包括 wrong_answer_type、intermediate_entity、mentioned_only、unsupported_or_artifact、comparison_direction。机制标签里 evidence_mislocalization 最多。

白话：

错误不是随机的。模型常常不是乱答，而是答了一个“证据里出现过、看起来合理、但不是最终答案”的东西。

7. **Selector isolation**

固定同一套 top-5 候选菜单（14B 生成的那份），只换 selector（裁判），看 final 会不会变。

- Top-5 不变 → 候选生成器锁死
- Final 会变 → 说明瓶颈不只在「有没有正确答案」，还在「选哪一个」

数据：MuSiQue dev 前 100 条，两种上下文：

- Full：全部段落
- Support-only：只用官方 supporting 段落（oracle 诊断）

模型：Qwen2.5-14B 的固定 top-5 + 不同 selector

Context	Selector	Final
Support-only	Original 14B（原始打分）	51/100
	Prompt-only support reranker	55/100
	Final-hop class 1.5B OOF	44/100
	Final-hop pairwise 1.5B OOF	46/100
Full	Original 14B	29/100
	Prompt-only support reranker	36/100
	Final-hop class 1.5B OOF	28/100
	Final-hop pairwise 1.5B OOF	35/100

候选生成器和选择器是两件事。正确答案已经摆桌上了，换一个“裁判”会改变结果。

8. **ECI 机制相图**

实体竞争越强，selection gap 是否越严重。

对 已有 MuSiQue dev100 结果 逐题算一个分数 ECI

ECI = 标准化(实体多) + 标准化(表面重叠) + 标准化(支持共现) + 标准化(候选实体多)

ECI 档位	Final	Top-5	Gap
Q1 最低	16/25	20/25	4
Q2	13/25	21/25	8
Q3	10/25	21/25	11
Q4 最高	12/25	24/25	12

高 ECI 区间 selection gap 更高，而 top5 仍然高。

当题里有很多像答案的实体时，模型不是找不到答案，而是更容易在一堆候选里选错。

9. **Evidence Graph Stress Test**

想发现什么：

证据图结构能不能解释 intermediate / bridge-like 错误。

发现：

graph features 比 schema-only 更能预测 bridge attraction 和 intermediate_entity 错误。

白话：

看候选类型不够，还要看实体在证据链里的位置。桥接实体如果在图里很显眼，就容易被当成最终答案。

10. Evidence Graph Causal Rewrites

想发现什么：

桥接实体显著性是不是因果因素，而不只是相关。

发现：

bridge downweight 把 final 从 0/35 提到 10/35，但 top5 从 35 掉到 30。说明它有因果作用，但粗暴处理会破坏证据链。

桥接实体确实会害模型选错；但不能简单把它删掉或匿名化，因为它也是推理链的一部分。

11. Selector Feature Ablation

想发现什么：

给 selector 更多信息是不是一定更好。

发现：

1.5B selector 里，加 full context 反而更差；support snippets、answer type、evidence graph 都不是直接万能药。

小模型不是信息越多越好。给太多上下文，它反而更容易被干扰。

12. Controlled Counterfactual Families

实验设计（一句话）

从 MuSiQue heldout100 里挑 40 个 selection-gap case（top5 对、final 错），每个 case 当成一个「错误家族」，在同一题上跑 7 种受控干预 + 1 个原始 baseline，看 accuracy 怎么变、错误类型怎么迁移。模型：Qwen2.5-14B-Instruct（answer-lines 生成）。

40 题构成：24 个 full-context + 16 个 support-only；原始错误分布：mentioned_only 25、intermediate_entity 7、unsupported/artifact 5、wrong_answer_type 3。

各干预 variant 总体结果

Variant	Final 正确	Top5 正确	Gap	相对 baseline 修对
original_context	0/40	40/40	40	—
final_support_front	18/40	35/40	17	18
bridge_sentence_front	14/40	37/40	23	14
candidate_order_shuffle	11/40	40/40	29	11
delete_bridge_entity	3/40	30/40	27	3

干预含义简述：

- final_support_front：把最终 hop 的支持句移到最前（oracle，用官方 answer 定位）
- bridge_sentence_front：把桥接句移到最前（增强桥显著性）
- delete/placeholder_bridge_entity：删桥实体 / 替换成占位符
- add_same/different_type_distractor：加同类型 / 不同类型干扰实体
- candidate_order_shuffle：固定候选列表顺序打乱（post-hoc，非新生成）

同一 selection-gap case 在不同干预下，错误在 intermediate / mentioned_only / correct 之间系统性迁移

`final_support_front` 主要修复 mentioned_only（15/25），支持 evidence-localization 机制

同类型干扰几乎不改变失败模式；桥/顺序干预会改变错误类型而非单纯提分

目前最像论文洞察的结论

> 在 sufficient-context QA 中，模型的关键瓶颈常常不是候选生成，而是 evidence-conditioned final-hop selection。这个瓶颈由答案类型约束、桥接实体显著性、mentioned-only 干扰、证据定位共同驱动；其中 bridge/entity salience 和 final support localization 是最稳定的机制信号。