2026.6.17

单跳与多跳实验结果 多跳为什么会暴露出更多的问题?

1. 单跳实验结果

MuSiQue 构造单跳对照

这里是从 MuSiQue 多跳问题中，根据官方 decomposition 拆出来的单跳问题。

主要看 `original_rank1` 结果。

模型	条件	final	top-5	selection gap
Qwen2.5-14B	多跳	45/100	69/100	24/100
Qwen2.5-14B	单跳 1	84/100	95/100	11/100
Qwen2.5-14B	单跳 2	61/100	80/100	19/100
Qwen2.5-7B	多跳	24/100	47/100	23/100
Qwen2.5-7B	单跳 1	73/100	86/100	13/100
Qwen2.5-7B	单跳 2	54/100	67/100	13/100
Qwen2.5-1.5B	多跳	17/100	28/100	11/100
Qwen2.5-1.5B	单跳 1	41/100	56/100	15/100
Qwen2.5-1.5B	单跳 2	26/100	40/100	14/100

结论：

- 7B 和 14B 上，多跳的 selection gap 明显比单跳更大。
- 14B：多跳 gap 是 24/100，单跳是 11/100 和 19/100。
- 7B：多跳 gap 是 23/100，单跳都是 13/100。
- 1.5B 不明显，因为它在多跳里 candidate miss 很严重，很多时候正确答案根本没进候选。

SQuAD 单跳 sanity check

这是普通单跳 QA 检查，不是 MuSiQue matched control。

模型	final	top-5	selection gap
Qwen2.5-14B	85/100	87/100	2/100
Qwen2.5-7B	75/100	77/100	2/100
Qwen2.5-1.5B	46/100	49/100	3/100

结论：

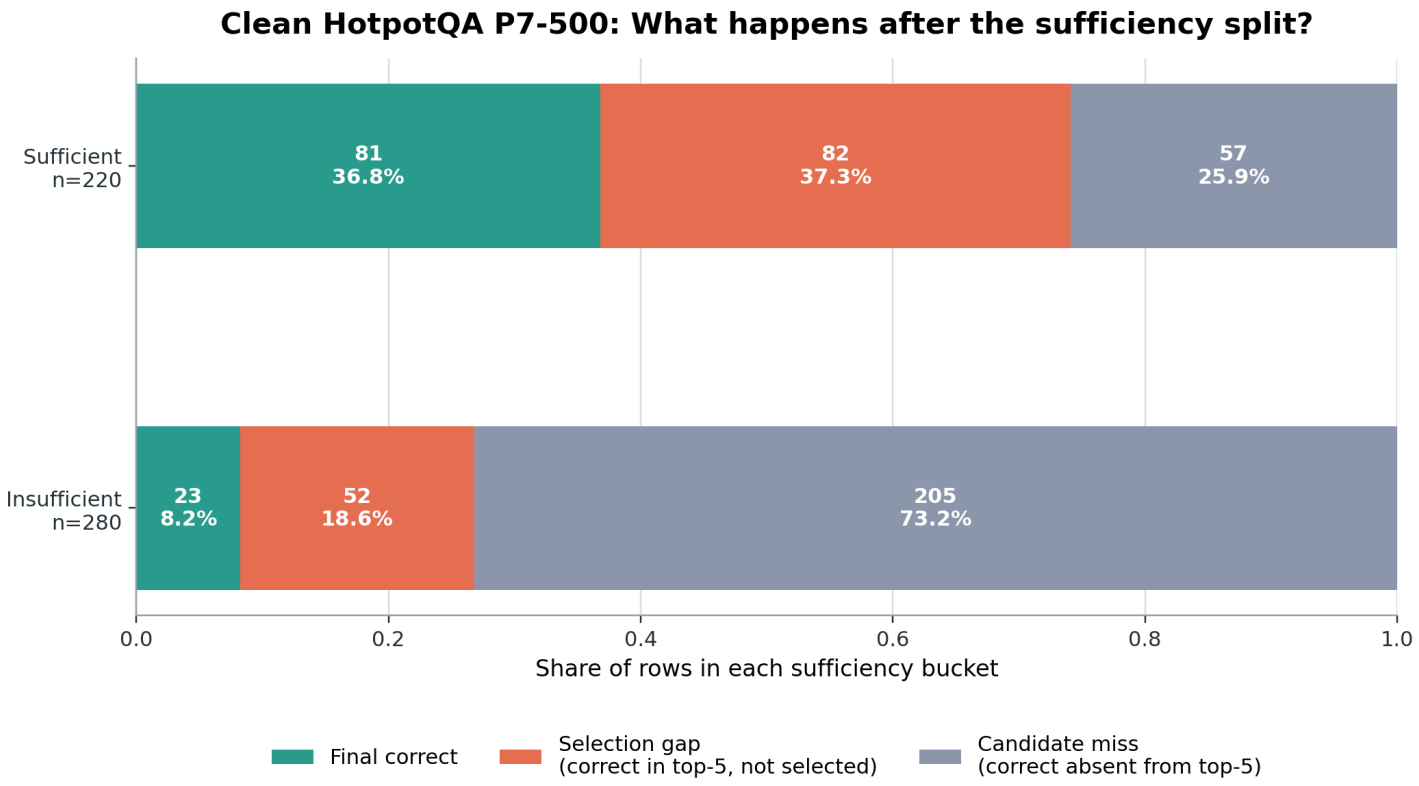
- 在普通单跳问题里，只要正确答案进入候选，模型基本能选对。
- SQuAD 单跳 selection gap 很小，只有 2-3/100。

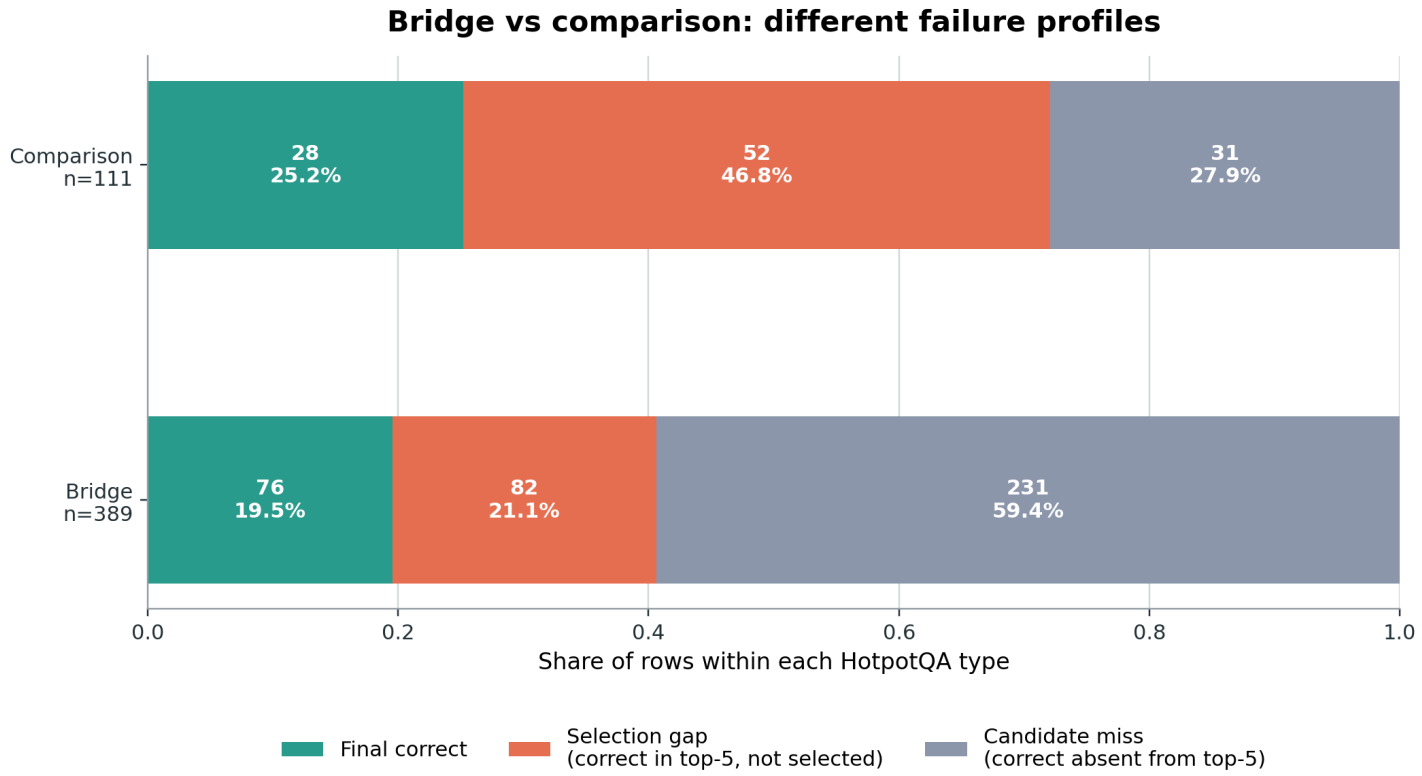
2. 多跳实验结果

MuSiQue 多跳结果

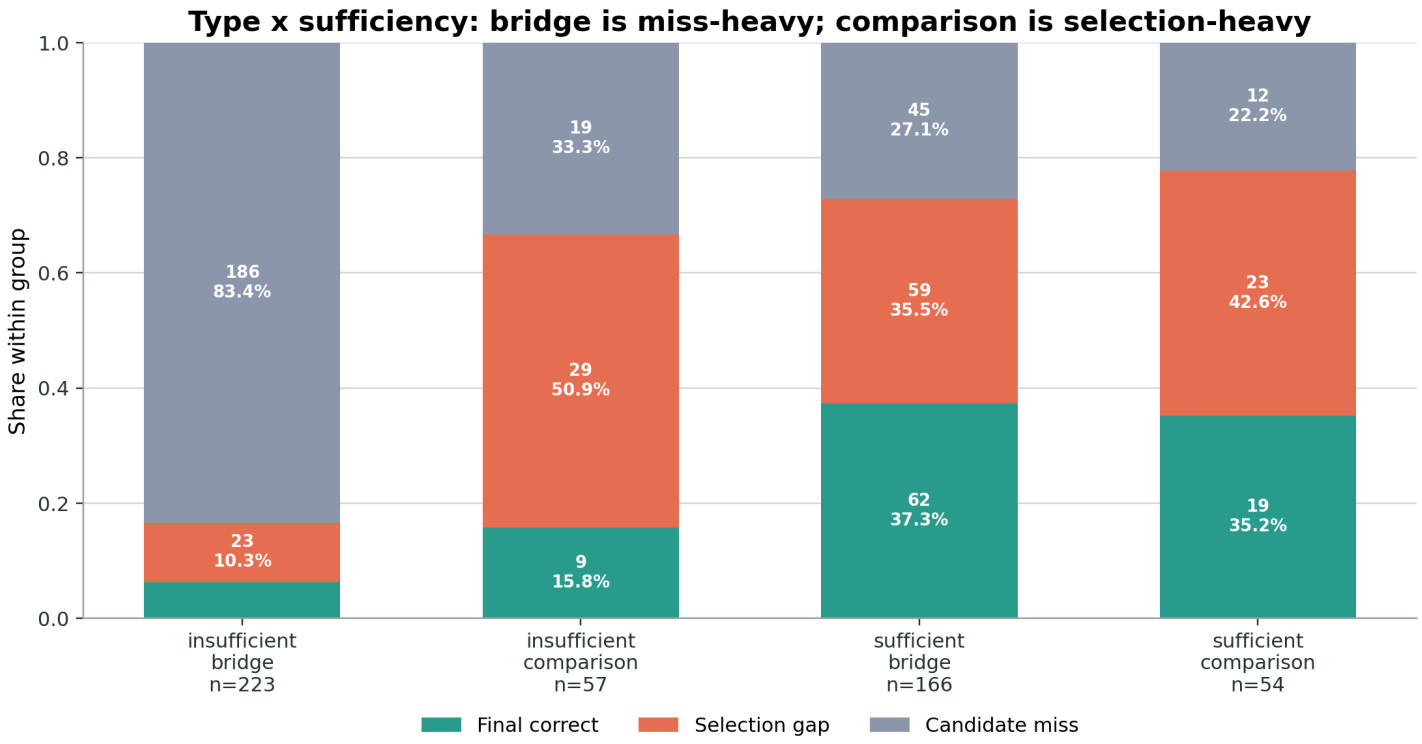
设置	final	top-5	selection gap
MuSiQue heldout100 full context	45/100	69/100	24/100

在数据充分的情况下，会暴露出哪些更多的问题

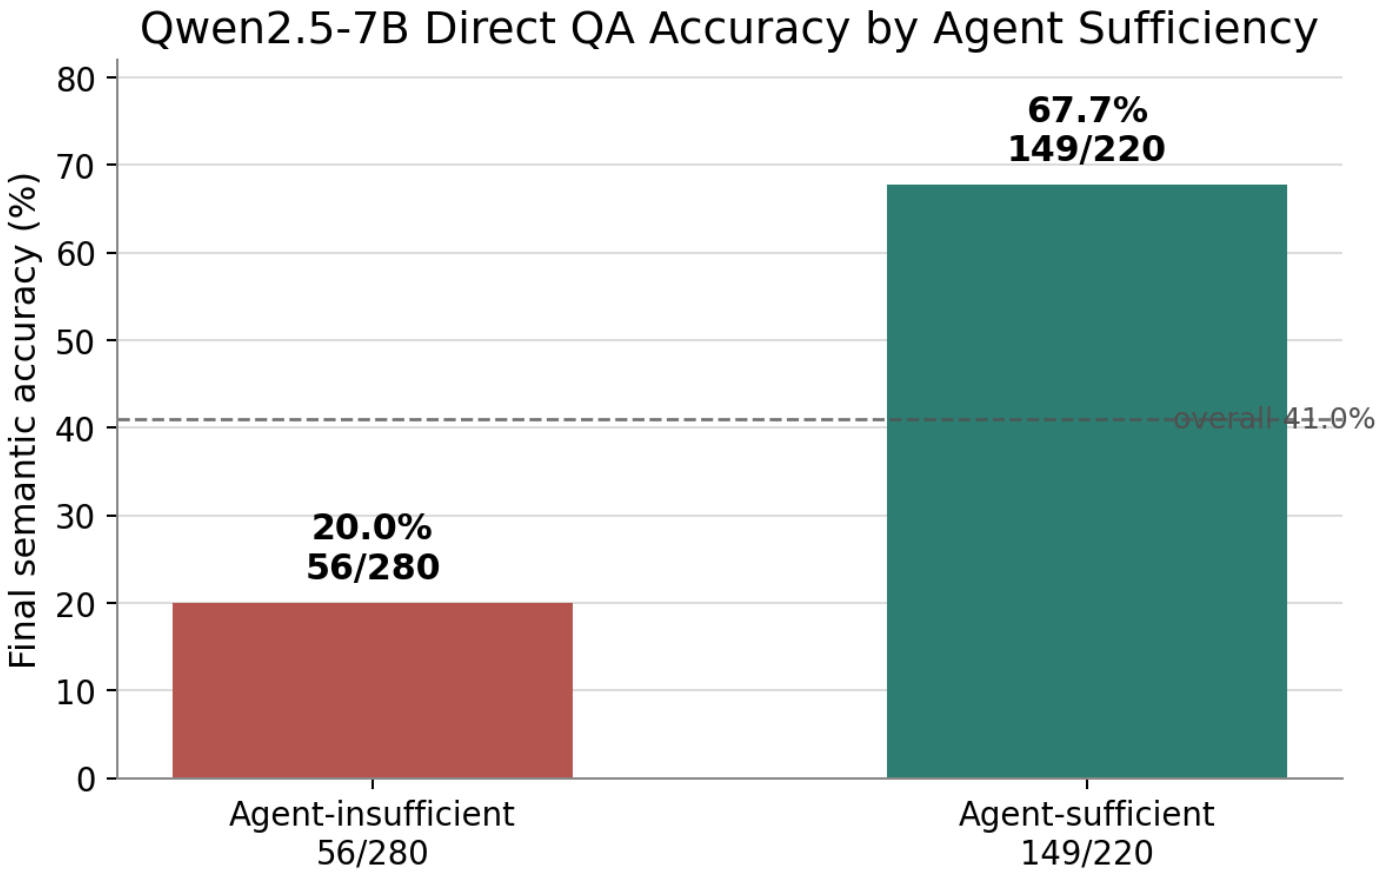




- bridge 题更偏“答案没进候选集”：231/389 = 59.4% 是 candidate miss。也就是说，多跳链条没接上，中间桥没搭好，最终答案根本没出现在可选答案里。
- comparison 题更偏“答案出现了但选错”：top-5 oracle 是 80/111 = 72.1%，但 final 只有 28/111 = 25.2%，selection gap 是 52/111 = 46.8%。也就是说，正确选项常常已经在候选里，但 7B 不会稳定比较并选中正确一边。



直接回答的准确率



HotpotQA P7 clean forced single-answer run. Agent sufficiency labels are internal judge labels, not human gold.